

Дипломна работа

Диана Генева <dageneva@qtrp.org>

2019

Съдържание

1	Нулева зона	2
2	Двойната звезда	3
2.1	Съчетаване чрез конкатенация на характеристичните вектори	3
2.1.1	Описание	3
2.1.2	Резултати	3
2.2	Съчетаване чрез максимизиране на ентропията	4
2.2.1	Описание	4
A	Приложение за Максимизиране на ентропията	5

Глава 1

Нулева зона

Глава 2

Двойната звезда

В предните раздели описахме получаването на класификатори за сигнали от реч и ЕЕГ поотделно. Сега въпросът е дали можем да съчетаем по някакъв начин данните или класификаторите с цел да получим по-добра класификационна точност. Разгледаните подходи са два. Първият е наивен и съчетава самите характеристични вектори, а вторият - вече получените класификатори.

2.1 Съчетаване чрез конкатенация на характеристичните вектори

2.1.1 Описание

Тук идеята е възможно най-проста - конкатенираме характеристичните вектори от речта и тези от ЕЕГ сигнала до получаване на нов вектор и тренираме класификатора, описан в ???. Единствената трудност е, че векторите за реч се взимат много по-често. За да има единакъв брой вектори за двата сигнала, тези за речта се осредняват на всеки 200 ms.

2.1.2 Резултати

На таблица [Таблица 2.1](#) е показана средната класификационна точност за всяка една от емоциите за двата класификатора поотделно и накрая за този, получен при конкатенацията на векторите. Всяка от Гаусовите смеси на класификатора на реч има 8 гаусиани, докато този за ЕЕГ и полученият при конкатенация имат по 3 гаусиани. От таблицата се вижда, че този метод не довежда до подобрение. Това вероятно се дължи на малкото количество данни, тъй като векторите, с които работим, са $39 + 76 = 115$ мерни. Това означава, че за да видим повече проявления на характеристиките, ще са нужни много повече данни. Освен набавянето на допълнително данни, може да се намали пространството чрез факторен анализ, за да се подобри обучението на класификатора.

Емоция	Само реч	Само ЕЕГ	Конкатенация
Гняв	85.00%	80.00%	85.00%
Щастие	75.00%	75.00%	50.00%
Неутрално	7.50%	97.50%	97.50%
Тъга	85.42%	87.50%	87.50%
Общо	63.23%	85.00%	80.00%

Таблица 2.1: Класификационна точност на класификатор за реч, класификатор за ЕЕГ и класификатор, получен при конкатенация на характеристичните вектори

2.2 Съчетаване чрез максимизиране на ентропията

2.2.1 Описание

Другият похват, който е приложен използва модел максимизиращ ентропията. Идеята е да намерим такова разпределение p върху входните данни, което изпълнява дадените ограничения, но в същото време не прави допълнителни предположения, тоест максимизира ентропията. Тоест имайки входни данни от вида $\mathcal{D} = (x_1, y_1) \dots (x_n, y_n)$, където $x_i \in X$ са характеристични вектори с етикети $y_i \in Y$, където $Y = \{1, \dots, K\}$ представя множеството от търсените емоции, искаме да максимизираме ентропията:

$$H(p) = - \sum_{(x,y) \in \mathcal{D}} p(x, y) \log(p(x, y))$$

и да бъде консистентно с ограниченията наложени от двата класификатора. Ако с h_1 бележим класификатора на реч

Приложение А

Приложение за Максимизиране на ентропията

Имаме множество от входни данни $\mathcal{D} = \{(x_1, y_1), \dots, (x_n, y_n)\}$, където $x_i \in X$ са характеристични вектори с етикети $y_i \in Y$. Търсим такова разпределение p върху \mathcal{D} , което да максимизира ентропията:

$$H(p) = - \sum_{(x,y) \in \mathcal{D}} p(x,y) \log(p(x,y))$$

и да изпълнява ограниченията, зададени с множество от характеристични функции $\mathcal{H}, |\mathcal{H}| = K$. Характеристичните функции са от вида $h_i : \mathcal{D} \rightarrow \{0, 1\}$.

$$\text{Нека } E(p, h) := \sum_{(x,y) \in \mathcal{D}} p(x,y) h(x,y)$$

Тогава ограниченията за търсеното p имат вида:

$$E(p, h) = E(\tilde{p}, h), \forall h \in \mathcal{H},$$

където с \tilde{p} означаваме емпиричната вероятност върху \mathcal{D} .

Тоест върху наличните данни, искаме това разпределение да се държи очаквано като емпиричното, но да не внася допълнителни предположения.

Нека P е множеството от всички разпределения, които изпълняват това условие. Тоест $P = \{p \mid E(p, h) = E(\tilde{p}, h), \forall h \in \mathcal{H}\}$.

Тогава искаме да намерим $\hat{p} = \operatorname{argmax}_{p \in P} H(p)$

Ще покажем, че \hat{p} трябва да има следния вид: $\hat{p}(x, y) = \pi \prod_{h_i \in \mathcal{H}} e^{\lambda_i h_i(x,y)}$ Тук $\lambda_i \in \mathbb{R}$ е тегло на съответната характеристична функция, а π е нормализираща константа, като тогава съществува единствено \hat{p} . Ще покажем и че това е еквивалентно на минимизирането на правдоподобие $L(p)$.

Нека с Q означим всички разпределения с желание вид. Имаме, че $Q = \{p \mid p(x, y) = \pi \prod_{h_i \in \mathcal{H}} e^{\lambda_i h_i(x,y)}\}$. За да намерим оптималното разпределение, ще ни е нужно да дефинираме разстояние между разпределения - "Разстояние" на

Кулбек-Лайблър:

$$D(p, q) = \sum_{(x, y) \in \mathcal{D}} p(x, y) \log \left(\frac{p(x, y)}{q(x, y)} \right)$$

“Разстоянието” на Кулбек-Лайблър всъщност не е разстояние в математическия смисъл (в смисъла на метрика), тъй като не е симетрична функция, но често се използва за разстояние между разпределения, тъй като има този интуитивен смисъл. Затова ще продължим да го наричаме разстояние, пропускайки кавичките.

С това сме готови да покажем следните твърдения:

Твърдение 1. За всеки две разпределения p и q , $D(p, q) \geq 0$, като $D(p, q) = 0 \iff p = q$

Доказателство: Тъй като p е разпределение и е изпълнено, че $\sum_{(x, y) \in \mathcal{D}} p(x, y) = 1$,

можем да приложим неравенството на Йенсен:

$$\sum_{i=1}^n p(x_i, y_i) f(z_i) \leq f \left(\sum_{i=1}^n p(x_i, y_i) z_i \right), \forall (z_1, \dots, z_n) \in \mathbb{R}^n,$$

където f е вдлъбната. Ако f е строго вдлъбната (f' е строго намаляваща), равенство се достига, когато z_i е константа.

$$\begin{aligned} -D(p, q) &= - \sum_{(x, y) \in \mathcal{D}} p(x, y) \log \left(\frac{p(x, y)}{q(x, y)} \right) \\ &= \sum_{(x, y) \in \mathcal{D}} p(x, y) \log \left(\frac{q(x, y)}{p(x, y)} \right) \\ &\leq \log \left(\sum_{(x, y) \in \mathcal{D}} \cancel{p(x, y)} \frac{q(x, y)}{\cancel{p(x, y)}} \right) \\ &\leq \log \left(\sum_{(x, y) \in \mathcal{D}} q(x, y) \right) = 0 \\ &\iff D(p, q) \geq 0 \end{aligned}$$

Тъй като логаритъмът е строго вдлъбната функция, равенство при неравенството на Йенсен се достига, когато $\frac{q(x, y)}{p(x, y)}$ е константа, тоест $\frac{q(x, y)}{p(x, y)} = 1 \iff p(x, y) = q(x, y)$ за произволно $(x, y) \in \mathcal{D}$.

Твърдение 2. За всеки $p_1, p_2 \in P, q \in Q$ е изпълнено $\sum_{(x, y) \in \mathcal{D}} p_1(x, y) \log(q(x, y)) = \sum_{(x, y) \in \mathcal{D}} p_2(x, y) \log(q(x, y))$

Доказателство:

$$\begin{aligned}
& \sum_{(x,y) \in \mathcal{D}} p_1(x,y) \log(q(x,y)) \\
&= \sum_{(x,y) \in \mathcal{D}} p_1(x,y) \log \left(\pi \prod_{h_i \in \mathcal{H}} e^{\lambda_i h_i(x,y)} \right) \\
&= \sum_{(x,y) \in \mathcal{D}} p_1(x,y) \left(\log(\pi) + \log \left(\prod_{h_i \in \mathcal{H}} e^{\lambda_i h_i(x,y)} \right) \right) \\
&= \sum_{(x,y) \in \mathcal{D}} p_1(x,y) \left(\log(\pi) + \sum_{h_i \in \mathcal{H}} \log(e^{\lambda_i h_i(x,y)}) \right) \\
&= \sum_{(x,y) \in \mathcal{D}} p_1(x,y) \left(\log(\pi) + \sum_{h_i \in \mathcal{H}} \lambda_i h_i(x,y) \right) \\
&= \sum_{(x,y) \in \mathcal{D}} p_1(x,y) \log(\pi) + \sum_{(x,y) \in \mathcal{D}} p_1(x,y) \sum_{h_i \in \mathcal{H}} \lambda_i h_i(x,y) \\
&= \log(\pi) \sum_{(x,y) \in \mathcal{D}} p_1(x,y) + \sum_{(x,y) \in \mathcal{D}} \sum_{h_i \in \mathcal{H}} p_1(x,y) \lambda_i h_i(x,y) \\
&= \log(\pi) \cdot 1 + \sum_{(x,y) \in \mathcal{D}} \sum_{h_i \in \mathcal{H}} p_1(x,y) \lambda_i h_i(x,y) \\
&= \log(\pi) \cdot 1 + \sum_{h_i \in \mathcal{H}} \lambda_i \sum_{(x,y) \in \mathcal{D}} p_1(x,y) h_i(x,y)
\end{aligned}$$

Тъй като $p_2 \in P$ то също изпълнява ограниченията.

$$= \log(\pi) \cdot 1 + \sum_{h_i \in \mathcal{H}} \lambda_i \sum_{(x,y) \in \mathcal{D}} p_2(x,y) h_i(x,y)$$

Използваме и че $\sum_{(x,y) \in \mathcal{D}} p_2(x,y) = 1$

$$\begin{aligned}
&= \log(\pi) \sum_{(x,y) \in \mathcal{D}} p_2(x,y) + \sum_{h_i \in \mathcal{H}} \lambda_i \sum_{(x,y) \in \mathcal{D}} p_2(x,y) h_i(x,y) \\
& \sum_{(x,y) \in \mathcal{D}} p_2(x,y) \log(q(x,y))
\end{aligned}$$

Твърдение 3. Ако $p \in P, q \in Q, r \in P \cap Q$, то $D(p, q) = D(p, r) + D(r, q)$

Доказателство:

$$\begin{aligned}
& D(p, r) + D(r, q) \\
&= \sum_{(x,y) \in \mathcal{D}} p(x, y) \log \left(\frac{p(x, y)}{r(x, y)} \right) + \sum_{(x,y) \in \mathcal{D}} r(x, y) \log \left(\frac{r(x, y)}{q(x, y)} \right) \\
&= \sum_{(x,y) \in \mathcal{D}} p(x, y) \log(p(x, y)) - \sum_{(x,y) \in \mathcal{D}} p(x, y) \log(r(x, y)) + \\
&\quad \sum_{(x,y) \in \mathcal{D}} r(x, y) \log(r(x, y)) - \sum_{(x,y) \in \mathcal{D}} r(x, y) \log(q(x, y)) \\
&\stackrel{\text{Твърдение 1}}{\leq} \\
&\quad \sum_{(x,y) \in \mathcal{D}} p(x, y) \log(p(x, y)) - \sum_{(x,y) \in \mathcal{D}} p(x, y) \log(r(x, y)) + \\
&\quad \sum_{(x,y) \in \mathcal{D}} \cancel{p(x, y) \log(r(x, y))} - \sum_{(x,y) \in \mathcal{D}} r(x, y) \log(q(x, y)) \\
&= \sum_{(x,y) \in \mathcal{D}} p(x, y) \log(p(x, y)) - \sum_{(x,y) \in \mathcal{D}} r(x, y) \log(q(x, y)) \\
&\stackrel{\text{Твърдение 1}}{\leq} \\
&\quad \sum_{(x,y) \in \mathcal{D}} p(x, y) \log(p(x, y)) - \sum_{(x,y) \in \mathcal{D}} \cancel{p(x, y) \log(q(x, y))} \\
&= \sum_{(x,y) \in \mathcal{D}} p(x, y) \log \left(\frac{p(x, y)}{q(x, y)} \right) = D(p, q)
\end{aligned}$$

Твърдение 4. Ако $r \in P \cap Q$, то r е единствено и $r = \hat{p}$

Доказателство:

Нека $r \in P \cap Q$. Условието $r = \hat{p}$ значи, че $r = \operatorname{argmax}_{p \in P} H(p)$, тоест ще покажем, че за всяко $p \in P : H(r) \geq H(p)$.

Нека u е равномерното разпределение върху \mathcal{D} , тоест $u(x, y) = \frac{1}{n}, \forall (x, y) \in \mathcal{D}$.

Следователно $u \in Q$, защото можем да изберем $\pi = \frac{1}{n}$ и $\lambda_i = 0, \forall i \in \{1 \dots K\}$

Нека фиксираме произволно $p \in P$. Тогава от **Твърдение 3** следва, че

$$D(p, u) = D(p, r) + D(r, u)$$

$$D(p, u) \stackrel{\text{Твърдение 1}}{\geq} D(r, u)$$

$$\begin{aligned} \sum_{(x,y) \in \mathcal{D}} p(x, y) \log \left(\frac{p(x, y)}{u(x, y)} \right) &\geq \sum_{(x,y) \in \mathcal{D}} r(x, y) \log \left(\frac{r(x, y)}{u(x, y)} \right) \\ -H(p) - \sum_{(x,y) \in \mathcal{D}} p(x, y) \log(u(x, y)) &\geq -H(r) - \sum_{(x,y) \in \mathcal{D}} r(x, y) \log(u(x, y)) \end{aligned}$$

Твърдение 2
 \longleftrightarrow

$$\begin{aligned} -H(p) - \sum_{(x,y) \in \mathcal{D}} p(x, y) \log(u(x, y)) &\geq -H(r) - \sum_{(x,y) \in \mathcal{D}} p(x, y) \log(u(x, y)) \\ H(r) &\geq H(p) \end{aligned}$$

Следователно $r = \operatorname{argmax}_{p \in P} H(p)$

Сега нека видим защо r е единствено. Нека $r' = \operatorname{argmax}_{p \in P} H(P)$. Тогава:

$$H(r') = H(r) \longleftrightarrow D(r, u) = D(r', u)$$

но $D(r, u) = D(r, r') + D(r', u)$ по **Твърдение 2**

$$\implies D(r, r') = 0$$

Твърдение 1
 $\implies r = r'$

Сега, нека дефинираме правдоподобие на разпределение p като при дадено множество \mathcal{D} :

$$\hat{L}_{\mathcal{D}}(p) = \prod_{(x,y) \in \mathcal{D}} p(x, y)$$

Тъй като логаритъмът е вдлъбната и монотонно растяща функция, често се разглежда за удобство:

$$\log(\hat{L}_{\mathcal{D}}(p)) = \sum_{(x,y) \in \mathcal{D}} \log(p(x, y))$$

Дефинираме функцията $L(p)$:

$$\begin{aligned} L(p) &= \sum_{(x,y) \in X \times Y} \tilde{p}(x, y) \log(p(x, y)) = \sum_{(x,y) \in \mathcal{D}} \tilde{p}(x, y) \log(p(x, y)) + \sum_{(x,y) \notin \mathcal{D}} \tilde{p}(x, y) \log(p(x, y)) \\ &= \sum_{(x,y) \in \mathcal{D}} \tilde{p}(x, y) \log(p(x, y)) + 0 \\ &= \sum_{(x,y) \in \mathcal{D}} \frac{1}{n} \log(p(x, y)) = C \log(\hat{L}_{\mathcal{D}}(p)) \end{aligned}$$

Тоест L е пропорционална на логаритъм от правдоподобие. Тоест, ако p максимизира L , то максимизира и правдоподобие, и обратното.

Твърдение 5. Ако $r \in P \cup Q$, то r е единствено и $r = \operatorname{argmax}_{q \in Q} L(q)$

Доказателство: Искаме да покажем, че за всяко $q \in Q : L(r) \geq L(q)$.

Нека фиксираме едно $q \in Q$, а \tilde{p} е емпиричното разпределение и следователно $\tilde{p} \in P$.

Тогава от **Твърдение 3** следва, че:

$$D(\tilde{p}, q) = D(\tilde{p}, r) + D(r, q)$$

$$D(\tilde{p}, q) \stackrel{\text{Твърдение 1}}{\geq} D(\tilde{p}, r)$$

$$-\cancel{H(\tilde{p})} - L(q) \geq -\cancel{H(\tilde{p})} - L(r)$$

$$\iff L(r) \geq L(q)$$

Сега нека $r' = \operatorname{argmax}_{q \in Q} L(q)$, тоест $L(r) = L(r') \implies D(\tilde{p}, r) = D(\tilde{p}, r')$.

Но по **Твърдение 3**, $D(\tilde{p}, r') = D(\tilde{p}, r) + D(r, r') \implies D(r, r') = 0 \stackrel{\text{Твърдение 1}}{\iff} r' = r$, следователно r е единствено.

От **Твърдение 4** и **Твърдение 5**, че ако вземем разпределение от сечението на P и Q , то е единствено и е равно на $\hat{p} = \operatorname{argmax}_{p \in P} H(p) = \operatorname{argmax}_{q \in Q} L(q)$. Тъй като L е пропорционално на правдоподобие, за да намерим търсеното разпределение е достатъчно да максимизираме правдоподобие.