

# Дипломна работа

Диана Генева <dageneva@qtrp.org>

2019

# Съдържание

1	Нулева зона	2
A	Приложение за AdaBoost	3

# Глава 1

## Нулева зона

Бла, бла, бла, аз съм толкова емоционална. Не знам



# Приложение А

## Приложение за AdaBoost

Ще разгледаме алгоритъма AdaBoost в дискретния случай, като доказателството следва това в samme.

Задачата е следната: Дадено е  $K$ -брой класове. Имаме тренировъчни данни  $M := (x_1, y_1), (x_2, y_2), \dots, (x_n, y_n), x_i \in X, y_i \in \{1 \dots K\}, i = 1 \dots n$  и множество  $\mathcal{H}$  от класификатори от вида  $h_i : X \times \{1 \dots K\} \rightarrow \{0, 1\}$ , където

$$h_i(x, y) = \begin{cases} 1, & \text{ако класът на } x \text{ е } y \\ 0, & \text{иначе} \end{cases}$$

и съответно  $\sum_{j=1}^K h_i(x, j) = 1$ . При дадена константа  $T$ , търсим линейна комбинация на функции от  $\mathcal{H}$ :

$$H = \sum_{i=1}^T \alpha_i h_i$$

която минимизира загубата на точност. По-точно, искаме да оптимизираме следната функция на загубата:

$$L_{0,1}(g, x, y) = \begin{cases} 0, & g(x, y) = \max(g(x, 1), \dots, g(x, K)) \\ 1, & \text{иначе} \end{cases}$$

Тоест, имаме загуба 1, ако класификаторът ни не е познал правилно класа и 0, в противен случай. Това може да се запише и по следния начин:

$$L_{0,1}(g, x, y) = \begin{cases} 0, & y = \operatorname{argmax}_j (g(x, j)) \\ 1, & \text{иначе} \end{cases}$$

съответно можем да добавим константа, която няма да промени минимизацията:

$$L_{0,1}(g, x, y) = \begin{cases} 0, & y = \operatorname{argmax}_j \left( g(x, j) - \frac{1}{K} \left( \sum_{k=1}^K g(x, k) \right) \right) \\ 1, & \text{иначе} \end{cases} = \begin{cases} 0, & g(x, y) - \frac{1}{K} \left( \sum_{j=1}^K g(x, j) \right) > 0 \\ 1, & \text{иначе} \end{cases}$$

Нека означим  $\tilde{g}(x, y) = g(x, y) - \frac{1}{K} \left( \sum_{j=1}^K g(x, j) \right)$ . Тоест, искаме да оптимизираме:

$$L_{0,1}(g, x, y) = \begin{cases} 0, & \tilde{g}(x, y) > 0 \\ 1, & \text{иначе} \end{cases}$$

Тъй като тази функция не е диференцируема, можем за удобство да използваме експоненциалната функция на загубата, дефинирана по следния начин:

$$l(g, x, y) = e^{-\tilde{g}(x, y)}$$

Освен че тя е диференцируема, имаме, че ако  $\tilde{g}(x, y) > 0$ ,  $l(g, x, y) > 0$  и ако  $\tilde{g}(x, y) \leq 0$ ,  $l(g, x, y) \geq 1$ , което означава, че  $l(g, x, y)$  ограничава отгоре  $L_{0,1}(g, x, y)$  и в някакъв смисъл е "по-песимистична".

AdaBoost алгоритъмът избира последователно функции  $h_i$  от  $\mathcal{H}$  и намира за всяка тегло  $\alpha_i$ .

С  $H_t$  ще означаваме линейната комбинация, получена от първите  $t$  избрани класификатори. Имаме, че:

$$\begin{aligned} H_t(x, y) &= \sum_{i=1}^t \alpha_i h_i(x, y) \\ &= H_{t-1}(x, y) + \alpha_t h_t(x, y) \end{aligned}$$

$$\begin{aligned} \tilde{H}_t(x, y) &= \\ &= H_{t-1}(x, y) + \alpha h_t(x, y) - \frac{1}{K} \left( \sum_{j=1}^K H_{t-1}(x, j) + \alpha h_t(x, j) \right) \\ &= H_{t-1}(x, y) - \frac{1}{K} \left( \sum_{j=1}^K H_{t-1}(x, j) \right) + \alpha \left[ h_t(x, y) - \frac{1}{K} \left( \sum_{j=1}^K h_t(x, j) \right) \right] \\ &= \tilde{H}_{t-1}(x, y) + \alpha \tilde{h}(x, y) \end{aligned} \tag{A.0.1}$$

$$H_0(x, y) = 0 \text{ и } \tilde{H}_0(x, y) = 0 \quad \forall x \in X, \forall y \in \{1 \dots K\} \tag{A.0.2}$$

На всяка итерация  $t$  на алгоритъма, дефинираме разпределение върху тренировъчните данни, което ще означаваме с  $\mathcal{D}_t$ , където  $\mathcal{D}_t(i)$  дава вероятност на  $i$ -тия пример. Идеята е да може да се даде по-голяма вероятност на тези примери, върху които предните  $t - 1$  избрани функции бъркат и да се избере тази функция, която се представя най-добре върху така претеглените данни. В началото на алгоритъма за  $\mathcal{D}_1$  избираме равномерно разпределение, тоест:

$$\mathcal{D}_1(i) = \frac{1}{n}, i = 1 \dots n$$

Алгоритъмът е следният:

1.  $D_1(i) = \frac{1}{n}, i = 1 \dots n$
2.  $H_0 = \emptyset$
3. За всяко  $t$  от 1 до  $T$  се прави следното:
  - 3.1.  $h_t = \operatorname{argmin}_{h \in \mathcal{H}} P_{i \sim D_t}(\tilde{h}(x_i, y_i) \leq 0)$
  - 3.2.  $\varepsilon_t = P_{i \sim D_t}(\tilde{h}(x_i, y_i) \leq 0)$
  - 3.3.  $\alpha_t = \ln\left(\frac{1 - \varepsilon_t}{\varepsilon_t}\right) + \ln(K - 1)$
  - 3.4.  $H_t = H_{t-1} \cup \{(h_t, \alpha_t)\}$
  - 3.5. За всяко  $i$  от 1 до  $n$ :
    - 3.5.1.  $\mathcal{D}_{t+1}(i) = \frac{\mathcal{D}_t(i) e^{-\alpha_t \tilde{h}_t(x_i, y_i)}}{\sum_{j=1}^n \mathcal{D}_t(j) e^{-\alpha_t \tilde{h}_t(x_i, y_j)}}$
4.  $H = H_T$
5. Връщаме  $H$

Целта на AdaBoost алгоритъмът е да се намери такова  $H$ , което минимизира експоненциалната грешка  $l$ .

За да видим, че горният алгоритъм намира такова  $H$ , ще докажем няколко твърдения.

Първо нека положим  $w_{t,i} = e^{-\tilde{H}_{t-1}(x_i, y_i)}$  за удобство.

**Твърдение 1.**  $\mathcal{D}_t(i) = \frac{w_{t,i}}{\sum_{j=1}^n w_{t,j}}$

Доказателство: Ще го докажем по индукция.

- База  $t = 1$

$$\begin{aligned} \frac{w_{1,i}}{\sum_{j=1}^n w_{1,j}} &= \frac{e^{-\tilde{H}_0(x_i, y_i)}}{\sum_{j=1}^n e^{-\tilde{H}_0(x_j, y_j)}} \\ &\stackrel{\text{A0.2}}{=} \frac{1}{n} \\ &\stackrel{\text{рег 1.}}{=} \mathcal{D}_1(i) \text{ за всяко } i \end{aligned}$$

- Нека твърдението е изпълнено за  $\mathcal{D}_t(i)$  за всяко  $i$

$$\bullet \mathcal{D}_t(i) = \frac{w_{t,i}}{\sum_{j=1}^n w_{t,j}} \Rightarrow \mathcal{D}_{t+1}(i) = \frac{w_{t+1,i}}{\sum_{j=1}^n w_{t+1,j}}$$

$$\begin{aligned} \mathcal{D}_{t+1}(i) &\stackrel{\text{рег 3.5.1.}}{=} \frac{\mathcal{D}_t(i) e^{-\alpha_t \tilde{h}_t(x_i, y_i)}}{\sum_{j=1}^n \mathcal{D}_t(j) e^{-\alpha_t \tilde{h}_t(x_j, y_j)}} \stackrel{\text{и} \times}{=} \frac{\frac{w_{t,i}}{\sum_{k=1}^n w_{t,k}} e^{-\alpha_t \tilde{h}_t(x_i, y_i)}}{\sum_{j=1}^n \frac{w_{t,j}}{\sum_{k=1}^n w_{t,k}} e^{-\alpha_t \tilde{h}_t(x_j, y_j)}} \\ &\stackrel{\text{def}}{=} \frac{\frac{e^{-\tilde{H}_{t-1}(x_i, y_i)}}{\sum_{k=1}^n e^{-\tilde{H}_{t-1}(x_k, y_k)}} e^{-\alpha_t \tilde{h}_t(x_i, y_i)}}{\sum_{j=1}^n \frac{e^{-\tilde{H}_{t-1}(x_j, y_j)}}{\sum_{k=1}^n e^{-\tilde{H}_{t-1}(x_k, y_k)}} e^{-\alpha_t \tilde{h}_t(x_j, y_j)}} \\ &= \frac{e^{-(\tilde{H}_{t-1}(x_i, y_i) + \alpha_t \tilde{h}_t(x_i, y_i))}}{\sum_{k=1}^n e^{-(\tilde{H}_{t-1}(x_k, y_k) + \alpha_t \tilde{h}_t(x_k, y_k))}} \frac{\sum_{k=1}^n e^{-\tilde{H}_{t-1}(x_k, y_k)}}{\sum_{j=1}^n e^{-(\tilde{H}_{t-1}(x_j, y_j) + \alpha_t \tilde{h}_t(x_j, y_j))}} \\ &= \frac{e^{-(\tilde{H}_{t-1}(x_i, y_i) + \alpha_t \tilde{h}_t(x_i, y_i))}}{\sum_{j=1}^n e^{-(\tilde{H}_{t-1}(x_j, y_j) + \alpha_t \tilde{h}_t(x_j, y_j))}} \stackrel{\text{A.0.1}}{=} \frac{e^{-\tilde{H}_t(x_i, y_i)}}{\sum_{j=1}^n e^{-\tilde{H}_t(x_j, y_j)}} \stackrel{\text{def}}{=} \frac{w_{t+1,i}}{\sum_{j=1}^n w_{t+1,j}} \end{aligned}$$

**Твърдение 2.**  $P_{i \sim D_t}(\tilde{h}(x_i, y_i) \leq 0) = \sum_{i: \tilde{h}(x_i, y_i) \leq 0} \frac{w_{t,i}}{\sum_{j=1}^n w_{t,j}}$

Доказателство: Използвайки горното твърдение, имаме че:

$$P_{i \sim D_t}(\tilde{h}(x_i, y_i) \leq 0) = \sum_{i: \tilde{h}(x_i, y_i) \leq 0} \mathcal{D}_t(x_i) = \sum_{i: \tilde{h}(x_i, y_i) \leq 0} \frac{w_{t,i}}{\sum_{j=1}^n w_{t,j}}$$

**Твърдение 3.** Изборът на  $h_t = \operatorname{argmin}_{h \in \mathcal{H}} P_{i \sim D_t}(\tilde{h}(x_i, y_i) \leq 0)$  от точка 3.2 на алгоритъма минимизира експоненциалната грешка на  $H_t$  върху тренировъчното множество, тоест:

$$h_t = \operatorname{argmin}_{h \in \mathcal{H}} \left( \frac{1}{n} \sum_{i=1}^n l(H_{t-1} + Ch, x_i, y_i) \right),$$

където  $C$  е произволна константа.

Доказателство:

$$\begin{aligned}
h_t &= \operatorname{argmin}_{h \in \mathcal{H}} \left( \frac{1}{n} \sum_{i=1}^n l(H_{t-1} + Ch, x_i, y_i) \right) \\
&= \operatorname{argmin}_{h \in \mathcal{H}} \left( \frac{1}{n} \sum_{i=1}^n e^{-(\tilde{H}_{t-1}(x_i, y_i) + C\tilde{h}(x_i, y_i))} \right) \\
&= \operatorname{argmin}_{h \in \mathcal{H}} \left( \frac{1}{n} \sum_{i=1}^n e^{-\tilde{H}_{t-1}(x_i, y_i)} e^{-C\tilde{h}(x_i, y_i)} \right)
\end{aligned}$$

Махаме константата  $\frac{1}{n}$ , тъй като тя не влияе на минимизацията, и заместваме с  $w_{t,i}$ .

$$= \operatorname{argmin}_{h \in \mathcal{H}} \left( \sum_{i=1}^n w_{t,i} e^{-C\tilde{h}(x_i, y_i)} \right)$$

Сега можем да разделим сумата на две, в зависимост  $\tilde{h}$  е сбъркал, тоест дали  $\tilde{h}(x_i, y_i) \leq 0$ . Ако това е изпълнено, то  $\tilde{h}(x_i, y_i) = h(x_i, y_i) - \frac{1}{K} \sum_{j=1}^K (h(x_i, j)) = 0 - \frac{1}{K} = -\frac{1}{K}$  и е равно на  $1 - \frac{1}{K}$  в противен случай, тоест:

$$\begin{aligned}
&= \operatorname{argmin}_{h \in \mathcal{H}} \left( \sum_{i: \tilde{h}(x_i, y_i) > 0} w_{t,i} e^{-C(1-1/K)} + \sum_{i: \tilde{h}(x_i, y_i) \leq 0} w_{t,i} e^{C/K} \right) \\
&= \operatorname{argmin}_{h \in \mathcal{H}} \left( \left[ \sum_{i=1}^n w_{t,i} e^{-C} - \sum_{i: h(x_i) \neq y_i} w_{t,i} e^{-C} \right] + \sum_{i: h(x_i) \neq y_i} w_{t,i} e^C \right) \\
&= \operatorname{argmin}_{h \in \mathcal{H}} \left( \sum_{i=1}^n w_{t,i} e^{-C} + \sum_{i: h(x_i) \neq y_i} w_{t,i} (e^C - e^{-C}) \right)
\end{aligned}$$

$\sum_{i=1}^n w_{t,i} e^{-C}$  е константа спрямо  $h$ , затова също не участва в минимизацията и тогава:

$$\begin{aligned}
&= \operatorname{argmin}_{h \in \mathcal{H}} \left( \sum_{i: h(x_i) \neq y_i} w_{t,i} (e^C - e^{-C}) \right) \\
&= \operatorname{argmin}_{h \in \mathcal{H}} \left( (e^C - e^{-C}) \sum_{i: h(x_i) \neq y_i} w_{t,i} \right)
\end{aligned}$$



Тъй като  $(e^C - e^{-C})$  не зависи от  $h$ :

$$= \operatorname{argmin}_{h \in \mathcal{H}} \left( \sum_{i: h(x_i) \neq y_i}^n w_{t,i} \right),$$

Можем да умножим по константата  $\frac{1}{\sum_{j=1}^n w_{t,j}}$  и да получим:

$$\begin{aligned} &= \operatorname{argmin}_{h \in \mathcal{H}} \left( \frac{\sum_{i: h(x_i) \neq y_i}^n w_{t,i}}{\sum_{j=1}^n w_{t,j}} \right), \\ &= \operatorname{argmin}_{h \in \mathcal{H}} \left( \sum_{i: h(x_i) \neq y_i}^n \frac{w_{t,i}}{\sum_{j=1}^n w_{t,j}} \right), \end{aligned}$$

$$\stackrel{\text{Твърдение 2}}{=} P_{i \sim D_t}(h(x_i) \neq y_i)$$

**Твърдение 4.** Изборът на  $\alpha_t$  от точка 3.3 на алгоритъма минимизира експоненциалната грешка на  $H_t$  върху тренировъчното множество, тоест:

$$\alpha_t = \operatorname{argmin}_{\alpha} \left( \frac{1}{n} \sum_{i=1}^n l(H_{t-1} + \alpha h_t, x_i, y_i) \right)$$

Доказателство:

$$\text{От точка 3.2 имаме, че } \varepsilon_t = P_{i \sim D_t}(h(x_i) \neq y_i) \stackrel{\text{Твърдение 2}}{=} \sum_{i: h(x_i) \neq y_i} \frac{w_{t,i}}{\sum_{j=1}^n w_{t,j}}$$

От предишното твърдение знаем, че:

$$\operatorname{argmin}_{\alpha} \left( \frac{1}{n} \sum_{i=1}^n l(H_{t-1} + \alpha h_t, x_i, y_i) \right) = \operatorname{argmin}_{\alpha} \left( \sum_{i: h(x_i) = y_i} w_{t,i} e^{-\alpha} + \sum_{i: h(x_i) \neq y_i} w_{t,i} e^{\alpha} \right)$$

Това, от което се интересуваме, е производната по  $\alpha$ .

$$\begin{aligned}
& \frac{\partial \left( \sum_{i:h(x_i)=y_i} w_{t,i} e^{-\alpha} + \sum_{i:h(x_i) \neq y_i} w_{t,i} e^{\alpha} \right)}{\partial \alpha} = 0 && \longleftrightarrow \\
& - \left( \sum_{i:h(x_i)=y_i} w_{t,i} \right) e^{-\alpha} + \left( \sum_{i:h(x_i) \neq y_i} w_{t,i} \right) e^{\alpha} = 0 && \longleftrightarrow \\
& \left( \sum_{i:h(x_i) \neq y_i} w_{t,i} \right) e^{\alpha} = \left( \sum_{i:h(x_i)=y_i} w_{t,i} \right) e^{-\alpha} && \longleftrightarrow \\
& e^{2\alpha} = \frac{\sum_{i:h(x_i)=y_i} w_{t,i}}{\sum_{i:h(x_i) \neq y_i} w_{t,i}} && \text{/логаритмуваме} \quad \longleftrightarrow \\
& 2\alpha = \ln \left( \frac{\sum_{i:h(x_i)=y_i} w_{t,i}}{\sum_{i:h(x_i) \neq y_i} w_{t,i}} \right) && \longleftrightarrow \\
& 2\alpha = \ln \left( \frac{\sum_{i=1}^n w_{t,i} - \sum_{i:h(x_i) \neq y_i} w_{t,i}}{\sum_{i:h(x_i) \neq y_i} w_{t,i}} \right) && \text{/умножаваме и делим на } \sum_{i=1}^n w_{t,i} \quad \longleftrightarrow \\
& 2\alpha = \ln \left( \frac{1 - \frac{\sum_{i:h(x_i) \neq y_i} w_{t,i}}{\sum_{i=1}^n w_{t,i}}}{\frac{\sum_{i:h(x_i) \neq y_i} w_{t,i}}{\sum_{i=1}^n w_{t,i}}} \right) && \text{/заместваме с } \varepsilon_t \quad \longleftrightarrow \\
& \alpha = \frac{1}{2} \ln \left( \frac{1 - \varepsilon_t}{\varepsilon_t} \right)
\end{aligned}$$

Което съвпада с избора на  $\alpha$  от точка 3.3 на алгоритъма.

От [Твърдение 3](#) и [Твърдение 4](#) следва, че полученото в точка 5. от алгоритъма  $H$  ще е с минимална експоненциална грешка върху тренировъчните данни.